

sanity_check

2025-07-13

Sanity Check do Dataframe

Nesta etapa, foi realizado um sanity check nos dados de voos com o objetivo de identificar possíveis inconsistências que possam comprometer a análise exploratória posterior. Foram verificadas duplicatas, presença de valores nulos nas colunas, e a integridade das categorias da variável `status_depart`, que será utilizada como target. Para isso, foi necessário validar a coerência entre a variável numérica `delay_depart` e sua versão categorizada `status_depart`.

Também foi avaliado o campo `outlier_depart_delay`, a fim de identificar possíveis valores anômalos atribuídos a categorias incorretas — especialmente aqueles classificados fora de “Atraso > 240”. Por fim, verificou-se a consistência na relação entre os aeroportos de origem e destino, assegurando que representem pares válidos entre aeroportos distintos.

Carregamento do dataframe

```
load("bfd_2022.rdata")

cols <- c("expected_depart", "real_depart", "expected_arrival", "real_arrival")

for (col in cols) {
  bfd[[col]] <- as.POSIXct(bfd[[col]])
}

head(bfd)
```

```
##   arrival depart      route company flight di type depart_day_period
## 1   BIKF   SBKP SBKP-BIKF    ICE   1080  7   I      Late Evening
## 2   CYHM   MROC MROC-CYHM    CJT   1592  7   I              Night
## 3   CYHM   KMIA KMIA-CYHM    CJT   1592  6   I      Early Evening
## 4   CYMX   SBFZ SBFZ-CYMX    CJT   1394  6   I      Mid Morning
## 5   CYUL   SBGR SBGR-CYUL    ACA    0097  0   I      Late Evening
## 6   CYUL   SBGR SBGR-CYUL    ACA    0097  0   I      Late Evening
##   arrival_day_period   expected_depart      real_depart
## 1      Mid Morning 2022-02-23 20:50:00 2022-02-23 23:50:00
## 2              Night 2022-01-09 23:30:00 2022-01-09 23:35:00
## 3      Late Evening 2022-03-21 17:50:00 2022-03-21 20:50:00
## 4      Early Evening 2022-05-08 09:00:00 2022-05-08 12:00:00
## 5      Early Morning 2022-01-01 22:00:00 2022-01-01 22:10:00
## 6      Early Morning 2022-01-03 21:55:00 2022-01-03 21:56:00
##   expected_arrival      real_arrival status_depart status_arrival
## 1 2022-02-24 09:25:00 2022-02-24 12:25:00 Atraso 120-240 Atraso 120-240
## 2 2022-01-10 04:20:00 2022-01-10 04:30:00 Pontual Pontual
## 3 2022-03-21 20:50:00 2022-03-21 23:50:00 Atraso 120-240 Atraso 120-240
## 4 2022-05-08 17:45:00 2022-05-08 20:45:00 Atraso 120-240 Atraso 120-240
## 5 2022-01-02 08:00:00 2022-01-02 08:24:00 Pontual Pontual
```

## 6	2022-01-04 07:55:00	2022-01-04 08:20:00	Pontual	Pontual
##	observation	delay_depart	delay_arrival	expected_flight_length
## 1	NA	180	180	755
## 2	NA	5	10	290
## 3	NA	180	180	180
## 4	NA	180	180	525
## 5	NA	10	24	600
## 6	NA	1	25	600
##	real_flight_length	outlier_depart_delay	outlier_arrival_delay	
## 1	755	FALSE	FALSE	
## 2	295	FALSE	FALSE	
## 3	180	FALSE	FALSE	
## 4	525	FALSE	FALSE	
## 5	614	FALSE	FALSE	
## 6	624	FALSE	FALSE	
##	outlier_expected_flight_consistency	outlier_real_flight_consistency		
## 1		FALSE	FALSE	
## 2		FALSE	FALSE	
## 3		FALSE	FALSE	
## 4		FALSE	FALSE	
## 5		FALSE	FALSE	
## 6		FALSE	FALSE	
##	outlier_expected_flight_length	outlier_real_flight_length		
## 1		FALSE	FALSE	
## 2		FALSE	FALSE	
## 3		FALSE	FALSE	
## 4		FALSE	FALSE	
## 5		FALSE	FALSE	
## 6		FALSE	FALSE	
##	depart_air_temperature	depart_dew_point	depart_relative_humidity	
## 1	23	20	83.21	
## 2	NA	NA	NA	
## 3	NA	NA	NA	
## 4	27	23	78.76	
## 5	20	19	93.97	
## 6	22	21	94.06	
##	depart_wind_direction	depart_wind_speed	depart_sky_coverage	depart_pressure
## 1	100	6	<NA>	29.94
## 2	NA	NA	<NA>	NA
## 3	NA	NA	<NA>	NA
## 4	160	8	FEW	29.91
## 5	80	4	<NA>	29.94
## 6	0	0	OVC	29.91
##	depart_visibility	depart_apparent_temperature	depart_wind_speed_scale	
## 1	6.21	23.00000	Light Breeze	
## 2	NA	NA	<NA>	
## 3	NA	NA	<NA>	
## 4	6.21	29.62222	Gentle Breeze	
## 5	6.21	20.00000	Light Breeze	
## 6	4.35	22.00000	Calm	
##	depart_wind_direction_cat	arrival_air_temperature	arrival_dew_point	
## 1	E	NA	NA	
## 2	<NA>	NA	NA	
## 3	<NA>	NA	NA	

```
## 4          SSE          NA          NA
## 5          E          NA          NA
## 6          N          NA          NA
## arrival_relative_humidity arrival_wind_direction arrival_wind_speed
## 1          NA          NA          NA
## 2          NA          NA          NA
## 3          NA          NA          NA
## 4          NA          NA          NA
## 5          NA          NA          NA
## 6          NA          NA          NA
## arrival_sky_coverage arrival_pressure arrival_visibility
## 1          <NA>          NA          NA
## 2          <NA>          NA          NA
## 3          <NA>          NA          NA
## 4          <NA>          NA          NA
## 5          <NA>          NA          NA
## 6          <NA>          NA          NA
## arrival_apparent_temperature arrival_wind_speed_scale
## 1          NA          <NA>
## 2          NA          <NA>
## 3          NA          <NA>
## 4          NA          <NA>
## 5          NA          <NA>
## 6          NA          <NA>
## arrival_wind_direction_cat
## 1          <NA>
## 2          <NA>
## 3          <NA>
## 4          <NA>
## 5          <NA>
## 6          <NA>
```

O dataset a ser trabalhado consiste em 845,160 linhas e 48 colunas referentes aos vôos no Brasil em 2022.

Análise de Duplicatas

```
bfd[duplicated(bfd), ]
```

```
## arrival depart route company flight di type depart_day_period
## 824724 SEQM SAEZ SAEZ-SEQM QTR 8157 0 G Early Morning
## arrival_day_period expected_depart real_depart expected_arrival
## 824724 Late Morning 2022-04-01 05:00:00 <NA> 2022-04-01 11:15:00
## real_arrival status_depart status_arrival observation delay_depart
## 824724 <NA> <NA> <NA> NA NA
## delay_arrival expected_flight_length real_flight_length
## 824724 NA 375 NA
## outlier_depart_delay outlier_arrival_delay
## 824724 NA NA
## outlier_expected_flight_consistency outlier_real_flight_consistency
## 824724 FALSE NA
## outlier_expected_flight_length outlier_real_flight_length
## 824724 FALSE NA
## depart_air_temperature depart_dew_point depart_relative_humidity
## 824724 NA NA NA
```

```
##      depart_wind_direction depart_wind_speed depart_sky_coverage
## 824724                NA                NA                <NA>
##      depart_pressure depart_visibility depart_apparent_temperature
## 824724                NA                NA                NA
##      depart_wind_speed_scale depart_wind_direction_cat
## 824724                <NA>                <NA>
##      arrival_air_temperature arrival_dew_point arrival_relative_humidity
## 824724                NA                NA                NA
##      arrival_wind_direction arrival_wind_speed arrival_sky_coverage
## 824724                NA                NA                <NA>
##      arrival_pressure arrival_visibility arrival_apparent_temperature
## 824724                NA                NA                NA
##      arrival_wind_speed_scale arrival_wind_direction_cat
## 824724                <NA>                <NA>
```

O dataframe completo possui apenas uma duplicata. Essa coluna possui informação repetida e deve ser removida.

Análise de quantidade nulos

```
quantidade_nulos <- bfd %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(cols = everything(), names_to = "coluna", values_to = "qtd_na") %>%
  arrange(desc(qtd_na))
```

```
quantidade_nulos
```

```
## # A tibble: 48 x 2
##   coluna          qtd_na
##   <chr>          <int>
## 1 observation      845160
## 2 depart_sky_coverage 304514
## 3 arrival_sky_coverage 303713
## 4 arrival_wind_direction 113150
## 5 arrival_wind_direction_cat 113150
## 6 depart_wind_direction 112521
## 7 depart_wind_direction_cat 112521
## 8 arrival_dew_point    86537
## 9 arrival_relative_humidity 86537
## 10 arrival_apparent_temperature 86537
## # i 38 more rows
```

O dataframe possui valores nulos na maioria das colunas. Em especial, a coluna 'observation' apresenta 100% de valores nulos, sendo inútil para as análises devido à ausência de informação e pode ser removida. Porém, o restante das colunas que possuem nulos apresenta uma quantidade que pode ser considerada. Por exemplo, as colunas 'depart_sky_coverage' e 'arrival_sky_coverage' possuem a maior quantidade de valores nulos depois da 'observation', correspondendo a ~36% de nulos.

Um ponto a ser observado também é que a coluna 'status_depart' possui 34,984 valores nulos. Como essa coluna é o target e é necessário possuir um valor para direcionar as análises para suas classes, o recomendado é validar sobre esses valores e removê-las caso essas linhas não possuam informação relevante mediante o target.

Análise e validação do target

```
table(bfd$status_depart, useNA = 'always')

##
##      Antecipado   Atraso > 240 Atraso 120-240   Atraso 30-60   Atraso 60-120
##      464193      3524          6596          35507          15721
##      Pontual      <NA>
##      284635      34984

bfd <- bfd %>%
  mutate(
    real_depart = as.POSIXct(real_depart),
    expected_depart = as.POSIXct(expected_depart),
    delay_depart_new = as.numeric(difftime(real_depart, expected_depart, units = "mins"))
  )

table(bfd$delay_depart == bfd$delay_depart_new, useNA = 'always')

##
##      TRUE      <NA>
## 810176  34984
```

Acima, recalculei o atraso dos vôos a partir da diferença do real e esperado. Após isso, observei a frequência relativa aos valores únicos presentes na comparação entre a coluna de atraso original 'delay_depart' e a nova 'delay_depart_new'.

Nota-se que são todos TRUE e possui uma quantidade NA igual à que já foi vista antes. Logo, a coluna de 'delay_depart' está correta.

```
bfd <- bfd %>%
  mutate(
    status_depart_new = case_when(
      is.na(delay_depart) ~ NA_character_,
      delay_depart < 0 ~ "Antecipado",
      delay_depart >= 0 & delay_depart <= 30 ~ "Pontual",
      delay_depart > 30 & delay_depart <= 60 ~ "Atraso 30-60",
      delay_depart > 60 & delay_depart <= 120 ~ "Atraso 60-120",
      delay_depart > 120 & delay_depart <= 240 ~ "Atraso 120-240",
      delay_depart > 240 ~ "Atraso > 240"
    )
  )

table(bfd$status_depart == bfd$status_depart_new, useNA = 'always')

##
##      TRUE      <NA>
## 810176  34984
```

Repetindo o processo pra coluna categórica de atraso, pode-se notar que a coluna de 'status_depart' também possui todos os seus valores originais corretos, inclusive os nulos.

Validação dos outliers

```
table(bfd %>%
  filter(outlier_depart_delay == TRUE) %>%
  select(status_depart))
```

```
## status_depart
## Atraso > 240
##          318
```

Pela análise de outliers existentes em ‘outliers_depart_delay’, parece que apenas 318 entre 3524 valores foram atribuídos à categoria “Atrasado > 240”. Isso faz sentido, além de que demonstra não haver outliers associados a outras categorias, o que já não faria mais tanto sentido, apenas se fosse outliers inferiores com um tempo de antecipação muito incomum.

Validação de Aeroportos (Decolagem e Chegada)

```
table(bfd$arrival == bfd$depart)
```

```
##
## FALSE TRUE
## 845157 3
```

```
bfd[bfd$arrival == bfd$depart, ]
```

```
## arrival depart route company flight di type depart_day_period
## 776736 SBSV SBSV SBSV-SBSV SID 9400 0 C Late Evening
## 825579 SEQM SEQM SEQM-SEQM QTR 8148 0 G Night
## 825606 SEQM SEQM SEQM-SEQM QTR 8148 0 G Night
## arrival_day_period expected_depart real_depart expected_arrival
## 776736 Night 2022-06-16 22:20:00 <NA> 2022-06-17 00:50:00
## 825579 Mid Morning 2022-11-21 04:50:00 <NA> 2022-11-21 10:10:00
## 825606 Mid Morning 2022-11-28 04:50:00 <NA> 2022-11-28 10:10:00
## real_arrival status_depart status_arrival observation delay_depart
## 776736 <NA> <NA> <NA> NA NA
## 825579 <NA> <NA> <NA> NA NA
## 825606 <NA> <NA> <NA> NA NA
## delay_arrival expected_flight_length real_flight_length
## 776736 NA 150 NA
## 825579 NA 320 NA
## 825606 NA 320 NA
## outlier_depart_delay outlier_arrival_delay
## 776736 NA NA
## 825579 NA NA
## 825606 NA NA
## outlier_expected_flight_consistency outlier_real_flight_consistency
## 776736 FALSE NA
## 825579 FALSE NA
## 825606 FALSE NA
## outlier_expected_flight_length outlier_real_flight_length
## 776736 FALSE NA
## 825579 FALSE NA
## 825606 FALSE NA
## depart_air_temperature depart_dew_point depart_relative_humidity
## 776736 26 18 61.36
## 825579 NA NA NA
## 825606 NA NA NA
## depart_wind_direction depart_wind_speed depart_sky_coverage
## 776736 150 10 FEW
## 825579 NA NA <NA>
```

##	825606	NA	NA	<NA>
##		depart_pressure	depart_visibility	depart_apparent_temperature
##	776736	30	6.21	26
##	825579	NA	NA	NA
##	825606	NA	NA	NA
##		depart_wind_speed_scale	depart_wind_direction_cat	
##	776736	Gentle Breeze	SSE	
##	825579	<NA>	<NA>	
##	825606	<NA>	<NA>	
##		arrival_air_temperature	arrival_dew_point	arrival_relative_humidity
##	776736	26	18	61.36
##	825579	NA	NA	NA
##	825606	NA	NA	NA
##		arrival_wind_direction	arrival_wind_speed	arrival_sky_coverage
##	776736	150	10	FEW
##	825579	NA	NA	<NA>
##	825606	NA	NA	<NA>
##		arrival_pressure	arrival_visibility	arrival_apparent_temperature
##	776736	30	6.21	26
##	825579	NA	NA	NA
##	825606	NA	NA	NA
##		arrival_wind_speed_scale	arrival_wind_direction_cat	delay_depart_new
##	776736	Gentle Breeze	SSE	NA
##	825579	<NA>	<NA>	NA
##	825606	<NA>	<NA>	NA
##		status_depart_new		
##	776736	<NA>		
##	825579	<NA>		
##	825606	<NA>		

Existem três vôos em que os aeroportos de decolagem e chegada são iguais, o que não faz sentido. Porém, serão descartados de qualquer forma já que o target também é NA.